

Phân tích và Dự đoán Chứng khoán Việt Nam thông qua ứng dụng Spark

23020345 – Phạm Tiến Dũng

Báo cáo BigData Assignment
Ngày 26 tháng 10 năm 2025

Tóm tắt nội dung

Báo cáo này trình bày một hệ thống phân tích và dự đoán giá chứng khoán Việt Nam, được xây dựng dựa trên dữ liệu từ 500 tệp CSV thu thập tự động từ thư viện **vnstock**. Hệ thống tận dụng các công nghệ trọng yếu trong hệ sinh thái Big Data là Apache Spark và Hadoop HDFS để xử lý dữ liệu quy mô lớn. Đồng thời, báo cáo kết hợp mô hình học sâu LSTM (Long Short-Term Memory) triển khai bằng PyTorch để dự đoán xu hướng giá cổ phiếu. Kết quả thực nghiệm chứng minh khả năng xử lý song song hiệu quả, tốc độ huấn luyện nhanh và độ chính xác cao trong các bài toán dự báo ngắn hạn.

Mục lục

1	Giới thiệu	3
1.1	Bối cảnh và Vấn đề	3
1.2	Mục tiêu và Giải pháp	3
2	Kiến trúc và Triển khai Hệ thống	3
3	Phân tích Dữ liệu Khám phá (EDA)	4
3.1	So sánh Xu hướng Giá các Cổ phiếu	4
3.2	Phân tích Kỹ thuật	4
3.3	Phân tích Biến động và Rủi ro	5
4	Xây dựng Mô hình Dự đoán LSTM	6
4.1	Chuẩn bị Dữ liệu và Kiến trúc Mô hình	6
4.2	Huấn luyện Mô hình	7
5	Kết quả Thực nghiệm và Đánh giá	7
5.1	So sánh Kết quả Dự đoán	7
5.2	Đánh giá Định lượng	8
5.3	Phân prediction-scatter.tích Sai số	8
5.4	Dự báo Tương lai	9
6	Kết luận và Hướng phát triển	10
6.1	Kết luận	10
6.2	Hướng phát triển	10
7	Mã nguồn	10

1 Giới thiệu

1.1 Bối cảnh và Vấn đề

Thị trường chứng khoán Việt Nam, với hàng triệu giao dịch mỗi ngày, là một nguồn dữ liệu chuỗi thời gian khổng lồ và phức tạp. Việc phân tích và dự đoán xu hướng giá cổ phiếu từ nguồn dữ liệu này không chỉ đòi hỏi các mô hình dự báo chính xác mà còn yêu cầu một hạ tầng đủ mạnh để xử lý dữ liệu lớn, đảm bảo tính linh hoạt và khả năng mở rộng. Các thách thức chính bao gồm:

- **Khối lượng dữ liệu lớn:** Dữ liệu lịch sử của hàng trăm mã cổ phiếu qua nhiều năm có thể lên đến hàng gigabyte hoặc terabyte.
- **Yêu cầu xử lý song song:** Để tăng tốc độ phân tích và huấn luyện mô hình, việc xử lý dữ liệu cần được thực hiện song song trên một cụm máy tính.
- **Độ chính xác của mô hình:** Dữ liệu giá chứng khoán có tính phi tuyến và phụ thuộc vào các yếu tố thời gian phức tạp, đòi hỏi các mô hình học sâu như LSTM để nắm bắt các xu hướng dài hạn.

1.2 Mục tiêu và Giải pháp

Để giải quyết các thách thức trên, báo cáo này đề xuất xây dựng một pipeline Big Data hoàn chỉnh, từ lưu trữ, xử lý, phân tích đến dự đoán giá chứng khoán. Giải pháp được xây dựng dựa trên các công nghệ và mô hình sau:

- **Hadoop HDFS:** Đóng vai trò là hệ thống lưu trữ phân tán, đảm bảo an toàn, khả năng chịu lỗi và truy xuất dữ liệu hiệu quả.
- **Apache Spark:** Là công cụ xử lý dữ liệu song song, thực hiện các tác vụ tổng hợp, thống kê, và chuẩn bị dữ liệu đầu vào cho mô hình học sâu.
- **PyTorch LSTM:** Là mô hình học sâu nhiều tầng, được lựa chọn để giải quyết bài toán dự đoán chuỗi thời gian (Time Series Forecasting).

2 Kiến trúc và Triển khai Hệ thống

Hệ thống được triển khai bằng Docker Compose, mô phỏng một cụm Big Data hoàn chỉnh bao gồm các thành phần sau:


- **1 NameNode và 4 DataNode:** Lưu trữ 500 file CSV trong HDFS tại thư mục /dataack.
- **1 Spark Master và 4 Spark Worker:** Mỗi worker được cấp phát 16 core và 12.6 GiB RAM để xử lý dữ liệu song song.
- **1 Jupyter Container:** Cung cấp môi trường lập trình, huấn luyện và kiểm thử mô hình.

3 Phân tích Dữ liệu Khám phá (EDA)

Dữ liệu được thu thập tự động qua thư viện `vnstock`, bao gồm lịch sử giao dịch của 500 mã cổ phiếu từ năm 2020 đến 2025 (ví dụ: ACB, BCM, BID, CTG, DGC, FPT,...). Bước đầu tiên là đọc dữ liệu từ HDFS bằng Spark và tính toán giá trị trung bình hàng ngày theo công thức: $\text{mean} = (\text{high} + \text{low})/2$. Sau đó, dữ liệu được chuyển sang Pandas DataFrame để thực hiện các bước trực quan hóa.

3.1 So sánh Xu hướng Giá các Cổ phiếu

Biểu đồ đường (Hình 1) thể hiện biến động giá trung bình của một số mã cổ phiếu tiêu biểu qua các năm, giúp nhận diện các xu hướng tăng trưởng và biến động chung.



Hình 1: Trực quan hóa biến động giá trung bình của một số cổ phiếu.


3.2 Phân tích Kỹ thuật

Để có cái nhìn chi tiết hơn, chúng tôi thực hiện hai phương pháp phân tích kỹ thuật phổ biến.

- **Biểu đồ nến (Candlestick Chart):** Hình 2 cung cấp thông tin chi tiết về giá mở cửa, đóng cửa, cao nhất và thấp nhất của cổ phiếu FPT trong 60 ngày gần nhất, giúp nhận diện các mẫu hình giá.
- **Đường trung bình động (Moving Average):** Hình 3 thể hiện đường MA ngắn hạn (10 ngày) và trung hạn (50 ngày) của FPT, giúp làm mượt dữ liệu và xác định xu hướng.




Hình 2: Biểu đồ nền giá cổ phiếu FPT (60 ngày cuối).




Hình 3: Giá đóng cửa và các đường trung bình động của cổ phiếu FPT.

3.3 Phân tích Biến động và Rủi ro

Phân phối lợi nhuận hàng ngày (daily return) là một chỉ số quan trọng để đánh giá mức độ biến động và rủi ro của một cổ phiếu. Hình 4 và 5 cho thấy lợi nhuận của các mã ACB, BCM, và BID chủ yếu tập trung quanh mức 0, với một vài biến động lớn (đuôi phân phối dài).



Hình 4: Phân phối lợi nhuận hàng ngày của một số mã cổ phiếu (Histogram).



Hình 5: Ước tính mật độ lợi nhuận hàng ngày (KDE).

4 Xây dựng Mô hình Dự đoán LSTM

4.1 Chuẩn bị Dữ liệu và Kiến trúc Mô hình

Dữ liệu được chia thành hai tập: **Train (2020-2023)** và **Test (2024-2025)**. Mô hình LSTM được xây dựng bằng PyTorch với 4 tầng tuần tự, mỗi tầng có 50 units và một lớp dropout (tỷ lệ 0.2) để chống overfitting. Dữ liệu đầu vào là một chuỗi 60 ngày giá liên tiếp để dự đoán cho ngày tiếp theo.

```
1 class LSTMRegressor(nn.Module):
```

```

2     def __init__(self, input_size=1, hidden_size=50, dropout_rate=0.2):
3         super(LSTMRegressor, self).__init__()
4         self.lstm1 = nn.LSTM(input_size, hidden_size, batch_first=True)
5         self.dropout1 = nn.Dropout(dropout_rate)
6         self.lstm4 = nn.LSTM(hidden_size, hidden_size, batch_first=True)
7         self.dropout4 = nn.Dropout(dropout_rate)
8         self.fc = nn.Linear(hidden_size, 1)
9
10    def forward(self, x):
11        out, _ = self.lstm1(x)
12        out, _ = self.lstm4(out)
13        out = self.dropout4(out[:, -1, :])
14        out = self.fc(out)
15        return out

```

Listing 1: Cấu trúc mô hình LSTM bằng PyTorch.

4.2 Huấn luyện Mô hình

Mô hình được huấn luyện trong 100 epoch với hàm mất mát MSE (Mean Squared Error) và trình tối ưu hóa Adam.

```

1 for epoch in range(epochs):
2     for X_batch, y_batch in train_loader:
3         outputs = model(X_batch)
4         loss = criterion(outputs, y_batch)
5         optimizer.zero_grad()
6         loss.backward()
7         optimizer.step()

```


Listing 2: Vòng lặp huấn luyện mô hình.

5 Kết quả Thực nghiệm và Đánh giá

Sau khi huấn luyện, mô hình được sử dụng để dự đoán giá trung bình cho năm 2025.

5.1 So sánh Kết quả Dự đoán

Hình 6 so sánh đường giá thực tế của cổ phiếu FPT với đường giá do mô hình dự đoán. Có thể thấy, mô hình đã nắm bắt khá tốt các xu hướng tăng giảm chính của giá cổ phiếu.



Hình 6: So sánh giá thực tế (đỏ) và giá dự đoán (xanh) của mã FPT.

5.2 Đánh giá Định lượng


Các chỉ số đánh giá hiệu suất của mô hình trên tập test cho mã FPT là:

- **Root Mean Squared Error (RMSE):** 4.9366
- **Mean Absolute Percentage Error (MAPE):** 3.97%

Với MAPE dưới 5%, có thể kết luận mô hình có độ chính xác cao trong bài toán dự báo ngắn hạn.


5.3 Phân prediction-scatter.tích Sai số

Để đánh giá sâu hơn, biểu đồ phân tán (Hình 7) cho thấy các điểm dự đoán tập trung khá tốt quanh đường chéo, chứng tỏ mô hình có độ chính xác cao.



Hình 7: Biểu đồ phân tán giữa giá trị thực tế và giá trị dự đoán.

Biểu đồ sai số theo thời gian (Hình 8) dao động quanh đường 0 cho thấy mô hình dự đoán tốt xu hướng chung mà không bị lệch hệ thống.



Hình 8: Biểu đồ sai số dự đoán theo thời gian.

5.4 Dự báo Tương lai

Mô hình được sử dụng để dự báo 10 ngày tiếp theo (từ ngày 24/10/2025). Kết quả cho thấy một xu hướng tăng giá ngắn hạn:

Ngày 24/10/2025: 96.01

Ngày 25/10/2025: 97.52

...

Ngày 33/10/2025: 107.02

6 Kết luận và Hướng phát triển

6.1 Kết luận

Hệ thống đã đạt được các mục tiêu đề ra, xây dựng thành công một pipeline Big Data hoàn chỉnh. Kết quả cho thấy:

- Spark và HDFS xử lý hiệu quả dữ liệu crawl tự động quy mô lớn.
- Mô hình LSTM đạt sai số thấp ($\text{MAPE} \approx 3.97\%$), phản ánh tốt xu hướng giá ngắn hạn.
- Kiến trúc hệ thống có khả năng mở rộng dễ dàng để huấn luyện đồng thời nhiều mã cổ phiếu khác.

6.2 Hướng phát triển

- Mở rộng huấn luyện đồng thời nhiều mã cổ phiếu với PySpark và `DistributedDataParallel`.
- Lưu kết quả dự đoán vào MongoDB và xây dựng một dashboard trực quan bằng Streamlit.
- Tích hợp dữ liệu thời gian thực qua Kafka và Spark Streaming để thực hiện dự báo trực tuyến.

7 Mã nguồn

Toàn bộ mã nguồn có tại GitHub: <https://github.com/deRuijter17/Stock-Price-main>

Tài liệu

- [1] Apache Spark Documentation. <https://spark.apache.org/docs/latest/>
- [2] Hadoop HDFS Overview. <https://hadoop.apache.org/docs/stable/>
- [3] PyTorch LSTM Reference. <https://pytorch.org/docs/stable/generated/torch.nn.LSTM.html>
- [4] vnstock API Documentation. <https://vnstocks.com/>